傅立叶的指挥棒——有关建立空域到频域的数学直觉

这篇文章是有关空域、频域、傅立叶变换、采样定理（Nyquist-Shannon Sampling Theorem）与混叠的笔记。

傅立叶在 1822 年的《热的解析理论》里面谈论过：任何函数，即便是那些不连续的、完全任意的函数，都可以表示为一堆正弦（sin）和余弦（cos）函数的叠加。

$$f(x) = \frac{a_0}{2} + \sum_{n=1}^{\infty} (a_n \cos(nx) + b_n \sin(nx))$$

P.S. 前提：狄利克雷条件，后续：吉布斯现象。
这个公式是一维傅里叶级数（1D Fourier Series），正弦波拥有频率 ω（周期长短），直到二维傅里叶变换时，正弦波才拥有“方向”。

DSP 和 DIP(Digital Image Processing) 的根本基石就在于，任何复杂信号（无论是一段音乐，还是一幅图像），都可以拆解成一堆不同频率、不同方向的纯粹正弦波/余弦波相加的结果。我们在现实世界处理的信号有两个工程特点，1. 能量有限（纯数世界，需满足狄利克雷条件）；2. 离散采样。

人类的视觉系统很大程度上像是在“演奏”傅里叶变换：从光线进入眼睛的那一刻起，大脑就在做频域分解了。更神奇的是，大脑能够在图像的每一个局部同时测量特定频率和方向的正弦波分量，当我们凝视一个物体时，神经元将图像分解为不同的空间频率，有的神经元对粗轮廓敏感，有的对细纹里敏感，大脑将这些不同空间频率的信号“重新合成”，拼凑出我们“看”到的。从这个角度看，人类的视觉感知机制，本质上就像在脑海中实时解谱一首由“空间频率”构成的交响乐。

图像是“波的合奏”。
万物皆乐音。

空域（Spatial Domain）

空域指的是图像平面本身，所有处理方法都是直接对图像的像素点进行操作（based on direct manipulation of pixels in an image）。

空域处理主要分为灰度/强度变换（Intensity Transformations）和空间滤波（Spatial Filtering）。
• Intensity Transformations 只针对单个像素点，新像素的值只取决于原像素点自己。其应用：对比度拉伸（Contrast Stretching）、图像反转（Negative）、Gamma 校正、直方图均衡化（Histogram Equalization）等。
• Spatial Filtering 针对像素的“邻域”（Neighborhood）。一个像素的新值，是由它自己以及它周围一圈邻居像素共同决定的。其应用：图像平滑/模糊（低通）、图像锐化/边缘提取（高通）、去噪等。

Point Processing/Intensity Transformations

$g(x,y) = T[f(x,y)]$，f 是输入图像，g 是输出图像，T 是算子/变换函数（Operator）。T 作用的是以 (x,y) 为中心的一个邻域（Neighborhood），the smallest possible neighborhood is of size 1x1，此时邻域退化成了单个像素点本身，进行点处理（Point Processing），公式简化为：

$$s = T(r)$$

其中 r 是原像素值，s 是新像素值，T 是一个简单的 Intensity (also called a gray-level, or mapping) Transformation Function. 以 Contrast Stretching 为例，获得更高的对比度的方法：设定阈值 K，原始灰度值低于 k 的像素，被映射到更低的 s（向纯黑 0 靠近），原始灰度值高于 k 的像素，被映射到更高的 s（向纯白 255 靠近），拉开明暗差距。

极限情况的阈值处理（Thresholding），当这个变换函数的斜率在 k 处陡峭到极致，变成一个阶跃函数 Step Function 时，所有 $< k$ 的像素直接变成 0（纯黑）；所有 $\geq k$ 的像素直接变成 1/255（纯白），这就是阈值化（Thresholding）。阈值化被用来当作一种简单的图像增强手段（把感兴趣的物体直接凸显出来），也是图像分割（Image Segmentation）的核心工具（把目标从背景中剥离出来）。

常用于点处理（Point Processing）的三大基本函数：
1. 图像反转（Negative）：$s = (L-1) - r$
2. 对数函数（Logarithmic Transformations），公式：$s = c\log(1+r)$。展开暗部，压缩亮部。
3. 幂律函数/Gamma 校正，公式：$s = c \cdot r^{\gamma}$，当 $\gamma < 1$ 时会把暗部拉亮（全图变亮）；当 $\gamma > 1$ 时会把除了最高亮区域之外的所有中暗部全部压黑，从而把高光部分从一片昏暗中“抠”出来，增强高亮区域的对比度。

如果我们不想要用单一的数学公式贯穿全图（Global Functions），很多时候我们会用分段线性变换函数（Piecewise-linear Transformation），比如对比度拉伸（Contrast Stretching）和灰度级切片（Intensity-level Slicing），还有比特平面切片（Bit-plane Slicing）。

在 Intensity Transformations 部分，最后描述下直方图处理（Histogram Processing）。它有两个关键公式：

1. 未归一化直方图（Unnormalized Histogram）

$$h(r_k) = n_k \quad \text{for } k = 0, 1, 2, \ldots, L-1$$

其中 r_k 是第 k 个灰度级的值（其中 $k = 0, 1, 2, \ldots, L-1$）。在 8-bit 图中，$r_0 = 0$（纯黑），$r_{255} = 255$（纯白）。n_k 是整幅图像 $f(x,y)$ 中，灰度值恰好等于 r_k 的像素点的总个数。$h(r_k)$ 反映了在 r_k 这个灰度上，图像里一共有多少个像素。两张画面一模一样的缩略图和超清大图，大图的 n_k 会比小图大成千上万倍，未归一化直方图受图像尺寸影响极深，无法直接做跨图像对比。

2. 归一化直方图（Normalized Histogram）

$$p(r_k) = \frac{h(r_k)}{MN} = \frac{n_k}{MN} \quad \text{for } k = 0, 1, 2, \ldots, L-1$$

$p(r_k)$ 表示在图像中随机挑选一个像素，其灰度值恰好为 r_k 的概率（Probability）。归一化之后，消除了分辨率的影响。还有就是，我们可以把 $p(r_k)$ 看作概率密度函数（PDF, Probability Density Function）的离散近似，利用连续随机变量的 CDF（累积分布函数）推导出直方图均衡化（Histogram Equalization）。

直方图的形状能决定图像的外观，如果像素概率近似于均匀分布（Uniform Distribution），那么它的视觉效果是明暗层次丰富、细节清晰的。那么我们能否设计一个自动化的变换函数 $s = T(r)$，不管输入的原图有多暗、多亮、对比度多差，经过 $T(r)$ 处理后，输出图像的直方图都能被强行“拉平”成均匀分布? 答案是能的，而且这个 $T(r)$ 只需要用到原图自身的直方图（累积分布函数 CDF）。

首先我们假设连续，然后推导，最后离散化（Discretization）。
变换函数 $T(r)$ 有两条绝对不能违反的条件：
1. 在区间 $0 \le r \le L-1$ 上，$T(r)$ 必须是严格单调递增的（Strictly Monotonically Increasing）。防止视觉颠倒。与此同时，如果 $T(r)$ 是严格单调递增的，那么反函数 $r = T^{-1}(s)$ 就存在，保证变换是完全可逆的。
2. 对于 $0 \le r \le L-1$，输出必须满足 $0 \le T(r) \le L-1$。

根据概率论的知识，

$$p_s(s)\, ds = p_r(r)\, dr$$

整理下，

$$p_s(s) = p_r(r) \left| \frac{dr}{ds} \right|$$

我们的目标是让输出图像的直方图变成平的（均匀分布/Uniform Distribution），

$$s = T(r) = (L-1) \int_0^r p_r(w)\, dw$$

它的 $p_s(s)$ 是一个常数，

$$p_s(s) = \frac{1}{L-1}$$

但绝对平坦的直方图往往会导致对比度过度拉伸，我们希望输出图像的直方图长成某种特定的形状 $p_z(z)$（比如参考另一张高清无篡改原图的直方图风格）。
已知，

$$s = T(r) = (L-1) \int_0^r p_r(w)\, dw$$

和

$$G(z) = (L-1) \int_0^z p_z(v)\, dv$$

相等对接，

$$G(z) = s = T(r)$$

得到一个反向推导（Inverse Mapping）：

$$z = G^{-1}(s) = G^{-1}[T(r)]$$

Spatial Filtering

Spatial filtering modifies an image by replacing the value of each pixel by a function of the values of the pixel and its neighbors. 每个像素的值是由该像素及其邻域像素的某种函数计算结果决定的，如果这种操作是线性的，那就是 linear spatial filter；如果是非线性的，那就是 nonlinear spatial filter。

filter 意指“过滤”不同频率的波形，按频率选通信号，是频域词汇。之所以在空间域用一个小窗口（Kernel/Mask）在像素上滑来滑去也能叫“空间滤波”（Spatial Filtering）是因为卷积定理（Convolution Theorem），空域中的空间卷积 (Spatial Convolution) 与频域中的点乘 (Frequency Multiplication) 的数学效果是等价的。The kernel is an array whose size defines the neighborhood of operation, 常常也被称为 mask, template, and window. In general, linear spatial filtering of an image of size $M \times N$ with a kernel of size $m \times n$ is given by the expression:

$$g(x, y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s, t) f(x + s, y + t)$$

其中 x 和 y 的取值不断变动，以确保 the center (origin) of the kernel 能恰好遍历图像 f 中的每一个像素一次。

对于这些对称的 Kernel 出现旋转 180° 之后长得和原来一模一样时，空间相关 ≡ 空间卷积。在 Linear System Theory 里，when the values of a kernel are symmetric about its center, correlation and convolution yield the same result. And a foundation of linear system theory is that convolving a function with an impulse yields a copy of the function at the location of the impulse. A discrete impulse of strength (amplitude) A located at coordinates (x_0, y_0) is defined as:

$$\delta(x - x_0, y - y_0) = \begin{cases} A & \text{if } x = x_0 \text{ and } y = y_0 \\ 0 & \text{otherwise} \end{cases}$$

the convolution of a kernel w of size $m \times n$ with an image $f(x, y)$, denoted by $(w \star f)(x, y)$, is defined as:

$$(w \star f)(x, y) = \sum_{s=-a}^{a} \sum_{t=-b}^{b} w(s, t) f(x - s, y - t)$$

This equation implements the sum of products process to which we refer as linear spatial filtering. That is, linear spatial filtering and spatial convolution are synonymous. However, that the order of the functions input into a correlation algorithm does make a difference, because correlation is neither commutative nor associative. 卷积满足交换律和结合律，相关不满足交换律和结合律。

Junction, 从空域到频域。

The tie between spatial- and frequency-domain processing is the Fourier transform. There are two fundamental properties relating the spatial and frequency domains:
1. Convolution, which is the basis for filtering in the spatial domain, is equivalent to multiplication in the frequency domain, and vice versa.
2. An impulse of strength A in the spatial domain is a constant of value A in the frequency domain, and vice versa.

就像这篇笔记开头所提那样，a function (e.g., an image) satisfying some mild conditions can be expressed as the sum of sinusoids of different frequencies and amplitudes. Thus, the appearance of an image depends on the frequencies of its sinusoidal components—change the frequencies of those components, and you will change the appearance of the image. 因此，我们将特定频段与图像特征联系起来。（比如天空往往是低频正弦波构成的。）Linear filtering is concerned with finding suitable ways to modify the frequency content of an image. In the spatial domain we do this via convolution filtering. In the frequency domain we do it with multiplicative filters. 频域中的 filter transfer function 类似于空域中的 filter kernel。

空域和频域中的线性滤波大致上有四类：低通，高通，and bandpass and bandreject filters. 后面三种类型的滤波器都可以由低通滤波器构建而成。P.S. 非线性的话，又比如中值滤波，最大最小值滤波。

线性与非线性操作在图像处理中的优劣势对比

操作类型	理论基础与优势	典型应用场景	代表性算法/算子
线性操作 (Linear Operations)	具备加性与齐次性，支持**傅里叶变换、频域分析与离散卷积**推导；数学推导完备，计算高效。	高斯平滑、图像锐化（拉普拉斯算子）、频域带通/低通滤波	高斯滤波、均值滤波、Sobel 算子、FFT 变换
非线性操作 (Nonlinear Operations)	**突破线性限制**；能够在保护边缘/细节的同时滤除特定类型的噪声（如椒盐噪声）。	去除脉冲噪声、形态学图像处理（腐蚀/膨胀）、动态范围压缩	中值滤波（Median Filter）、最大/最小值滤波、伽马校正 (Gamma Correction)、直方图均衡化

Figure 1: Linear Operations and Nonlinear Operations

Frequency Domain

我们看见的永远只是不同的“颜色”和“亮度”——一个由各色明暗光线构成的场域。因此，用来描述视觉世界的傅立叶波，就是横贯视场并起伏变化着的光强信号。描述我们眼前的视觉世界的最直接的一种方式，就是逐个记录下视场中每个位置上的光强。但是这种方法要求记录每一个位置，而视觉的场域是一个连续的整体——其中的光点有无限多个，无论我们选择的两个点彼此多么靠近，永远有其他点位存在于它们之间，我们不可能穷尽所有位置，因此，数位图像是我们对连续世界进行离散采样得到的信号集合。（离散的、颗粒化的数

字信号的概念直到 1933 年才完全形成。）

Roadmap: 数位图像，电磁波谱，带宽（bandwidth）
数位图像的定义是什么？ An image may be defined as a two-dimensional function, $f(x, y)$, where x and y are spatial (plane) coordinates, and the amplitude of f at any pair of coordinates (x, y) is called the intensity or gray level of the image at that point. When x, y, and the intensity values of f are all finite, discrete quantities, we call the image a digital image. 这段是 Gonzalez 的解释，数字图像是当 x、y 以及 f 的强度值均为有限且离散的量时。P.S. 数位图像不仅仅局限于人类的可见光波段，imaging machines cover almost the entire electromagnetic (EM) spectrum.

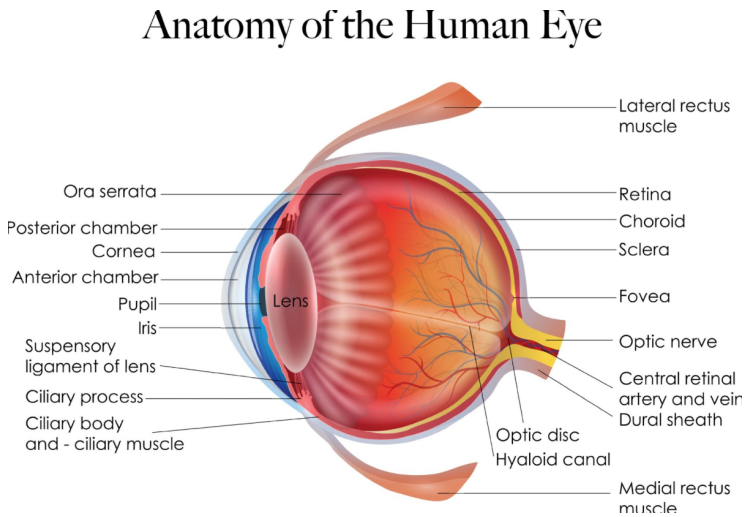


Figure 2: Human eye optical structure and sensing components. Source: TefiM / Getty Images

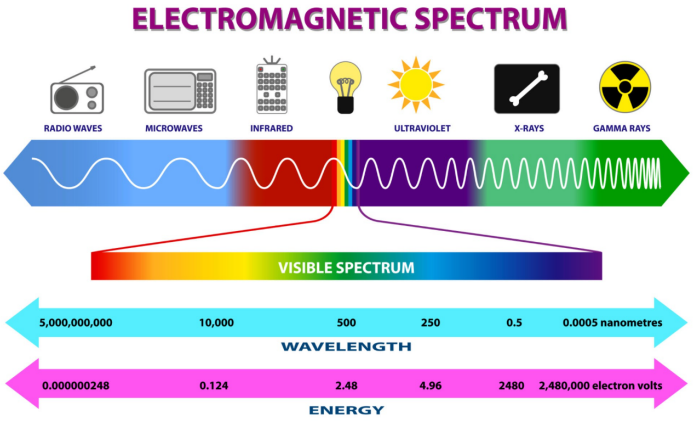


Figure 3: Electromagnetic spectrum from radio waves to gamma rays. Source: coolvectormaker / Getty Images

数位图像处理的人为分阶：There are no clear-cut boundaries in the continuum from image processing at one end to computer vision at the other. The history of digital image processing is intimately tied to the development of the digital computer which includes data storage, display, and transmission. 我们就遵循一个简单的范式：降低噪声的图像预处理、对比度增强以及图像锐化等视为低级处理（特点是输入和输出均为图像）；进行分割并将其描述为适合计算机处理的形式以及分类识别等视为中级处理（特点是输入通常为图像，输出是从图像中提取出的特征属性，例如边缘、轮廓）；高级处理 involves "making sense" of an ensemble of recognized objects，具备分析和认知能力。

基于频域信号分析，从连续到离散是傅里叶变换的数学基石。在取证视角下，图像不是一幅画，而是一个二维离散空间信号 $f(x,y)$。二维离散傅里叶变换 (2D DFT) 的正变换将空间域信号投影到一组正交复指数基函数上：

$$F(u,v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x,y) e^{-j2\pi\left(\frac{ux}{M}+\frac{vy}{N}\right)}$$

逆变换（IDFT）重构空间信号：

$$f(x,y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u,v) e^{j2\pi\left(\frac{ux}{M}+\frac{vy}{N}\right)}$$

其中，x, y 为空间坐标（像素索引），u, v 为频域坐标（空间频率）。复数表达：$F(u,v) = R(u,v) + jI(u,v)$。在取证分析中，我们极少直接观察复数矩阵 $F(u,v)$，而是将其分解为幅度谱与相位谱：

傅里叶谱 (Fourier Spectrum/ Magnitude)

$$|F(u,v)| = \sqrt{R^2(u,v) + I^2(u,v)}$$

相位谱 (Phase Spectrum)

$$\phi(u,v) = \arctan\left(\frac{I(u,v)}{R(u,v)}\right)$$

功率谱 (Power Spectrum)

$$P(u,v) = |F(u,v)|^2 = R^2(u,v) + I^2(u,v)$$

为了便于可视化与对称分析，通常将低频分量移动到频谱中心 $(M/2, N/2)$。利用傅里叶变换的平移性质，在空间域将像素乘以 $(-1)^{x+y}$，即可直接实现频域中心的平移。

$$\mathcal{F}\left\{f(x,y)(-1)^{x+y}\right\} = F\left(u - \frac{M}{2}, v - \frac{N}{2}\right)$$

Sampling and the Fourier Transform of Sampled Functions

如何在波和比特之间来回转换?
苏联科学家弗拉基米尔 · 科捷利尼科夫于 1933 年建立的理论，其正式名称是“采样定理”（Sampling Theorem）。怎样才能用有限数量的离散比特——像素——来代替一个平滑连续的视觉场景，同时在此过程中保留无穷多的信息呢? 采样定理会给我们答案。

取证中最关键的物理限制之一是采样定理。奈奎斯特-香农采样定理：若连续信号的最大频率为 f_{max}，采样频率必须满足 $f_s > 2f_{max}$ 才能无失真重构。混叠（Aliasing）是当采样率不足时，高于奈奎斯特频率的高频成分会“折叠”回低频区域，表现为高频混叠伪影（如伪摩尔纹）。

考虑一个连续函数 $f(t)$，我们希望沿着自变量 t 以均匀间隔 ΔT 对其进行采样，我们首先假设该函数在 t 轴上的范围是从 $-\infty$ 延伸到 ∞。用 $f(t)$ 乘以一个由间隔为 ΔT 的冲激序列构成的采样函数，

$$\tilde{f}(t) = f(t)s_{\Delta T}(t) = \sum_{n=-\infty}^{\infty} f(t)\delta(t - n\Delta T)$$

该求和公式中的每一个分量，都是一个由 $f(t)$ 在冲激所在位置的值所加权的冲激（Impulse）。$s_{\Delta T}(t)$ 是一个由无限个相距 ΔT 的冲激函数组成的“梳状函数”。连续信号 $f(t)$ 被“采样”的数学本质，就是连续信号与冲激梳在时域/空间域做乘法。采样前：$f(t)$ 是定义在连续轴 $t \in \mathbb{R}$ 上的光滑函数。采样后：$\tilde{f}(t)$ 是一串位置在 $t = n\Delta T$ 处、强度为 $f(n\Delta T)$ 的脉冲流。每个采样点的值由加权冲激的“强度”给出，我们可以通过积分来获取它。也就是说，采样序列中任意一个采样点 f_k 的值由下式给出：

$$f_k = \int_{-\infty}^{\infty} \tilde{f}(t)\delta(t - k\Delta T)\, dt = f(k\Delta T)$$

这个性质在数学上把“连续积分”直接抽样成了“离散数值 $f_k = f(k\Delta T)$”，这就是离散数字图像像素点阵的由来。根据卷积定理，我们知道空间域中两个函

数乘积的傅里叶变换，等于这两个函数各自变换在频域中的卷积。因此，采样函数的傅里叶变换为：

$$\tilde{F}(\mu) = \mathcal{F}\{\tilde{f}(t)\} = \mathcal{F}\{f(t)s_{\Delta T}(t)\} = F(\mu) * S_{\Delta T}(\mu)$$

利用一维卷积的定义，得到 $F(\mu)$ 和 $S(\mu)$ 的卷积：

$$\begin{aligned}
\tilde{F}(\mu) = F(\mu) * S_{\Delta T}(\mu) &= \int_{-\infty}^{\infty} F(\tau) S_{\Delta T}(\mu - \tau) d\tau \\
&= \int_{-\infty}^{\infty} F(\tau) \left[\frac{1}{\Delta T} \sum_{n=-\infty}^{\infty} \delta\left(\mu - \tau - \frac{n}{\Delta T}\right) \right] d\tau \\
&= \frac{1}{\Delta T} \sum_{n=-\infty}^{\infty} \int_{-\infty}^{\infty} F(\tau) \delta\left(\tau - \left(\mu - \frac{n}{\Delta T}\right)\right) d\tau \\
&= \frac{1}{\Delta T} \sum_{n=-\infty}^{\infty} F\left(\mu - \frac{n}{\Delta T}\right)
\end{aligned}$$

物理量 $1/\Delta T$ 是用于生成采样函数的采样率。为了让中心周期（原点附近的 $F(\mu)$）与相邻周期（位于 $\pm\frac{1}{\Delta T}$ 处）不发生交叠（Overlap），相邻频带之间的中心距离必须大于频带精细宽度的两倍：

$$\frac{1}{\Delta T} > 2\mu_{\max} \implies f_s > 2\mu_{\max}$$

这就是奈奎斯特采样定理：采样率 f_s 必须严格大于信号最高频率的两倍，才能完全保留原信号的信息。临界采样率 $2\mu_{\max}$ 被称为奈奎斯特率（Nyquist Rate）。临界频率 $\frac{1}{2\Delta T}$ 被称为奈奎斯特极限频率（Nyquist Frequency）。

Aliasing

混叠的物理本质是“伪装”和“不确定性”。当对连续信号进行采样时，如果采样率过低，不同的连续信号在采样点上的取值可能完全重合。采样后的离散序列无法区分它们，高频信号因此“伪装”成了低频信号。举个例子，车轮倒转现象（Temporal Aliasing）：电影中高速旋转的车轮看起来在慢速倒转，就是因为摄像机的帧率（采样率）低于车轮旋转频率的 2 倍。当采样率低于奈奎斯特率（$f_s < 2\mu_{\max}$）时，频域中周期延拓的副本会互相交叠（Overlap），此时即便使用理想低通滤波器（Ideal Lowpass Filter）试图把中心频带抠出来，相邻频带的高频成分也已经污染（Corrupt）了中心频带。对这个被污染的频谱做逆傅里叶变换(IDFT),得到的还原函数 $f_a(t)$ 包含了原信号中根本不存在的低频伪影。

在物理现实中，任何有限大小的图像都不可能是严格带限的。因此，数字图像采样中“混叠”绝对无法被完全消除，只能被抑制。混叠一旦发生，在数字空间是不可逆的。采样后，高频能量已经折叠并污染了低频能量，任何后处理算法（如解卷积、锐化）都无法区分哪些低频是真实的，哪些是高频混叠过来的。唯一解决方案：必须在采样之前（在光学或模拟信号阶段），使用低通滤镜（Anti-aliasing Filter）将高于奈奎斯特极限的高频成分提前平滑滤除。

P.S. 摩尔纹比数字混叠更广义，但数字混叠会在空间域表现为摩尔纹。

DFT

已知，

$$\tilde{f}(t) = \sum_{n=-\infty}^{\infty} f(t)\delta(t - n\Delta T)$$

代入连续傅里叶变换定义公式：

$$\tilde{F}(\mu) = \int_{-\infty}^{\infty} \tilde{f}(t)e^{-j2\pi\mu t}dt = \int_{-\infty}^{\infty} \left[\sum_{n=-\infty}^{\infty} f(t)\delta(t - n\Delta T)\right] e^{-j2\pi\mu t}dt$$

根据冲激函数的筛选性质（Sifting Property），只有当 $t = n\Delta T$ 时积分才有值，因此积分与求和号交换后化简为：

$$\tilde{F}(\mu) = \sum_{n=-\infty}^{\infty} f_n e^{-j2\pi\mu n\Delta T}$$

此时，虽然输入的信号 f_n 是离散的，但它的频谱 $\tilde{F}(\mu)$ 依然是一个关于连续变量 μ 的连续且无限周期的函数（周期为 $\frac{1}{\Delta T}$）。计算机无法存储连续的 $\tilde{F}(\mu)$。

既然 $\tilde{F}(\mu)$ 在频域是周期的（周期为 $\frac{1}{\Delta T}$），计算机只需要记录一个周期内的信息。假设我们在一个周期内等间隔地抽取 M 个频点，采样频点设为：

$$\mu = \frac{m}{M\Delta T}, \quad m = 0, 1, 2, \ldots, M - 1$$

将 μ 代入公式，此时指数项中的 ΔT 被消相：

$$\mu \cdot n\Delta T = \left(\frac{m}{M\Delta T}\right) \cdot n\Delta T = \frac{mn}{M}$$

令 $F_m = \tilde{F}\left(\frac{m}{M\Delta T}\right)$，限制求和在一个周期 M 范围内，得到著名的 DFT 离散傅里叶变换：

$$F_m = \sum_{n=0}^{M-1} f_n e^{-j2\pi mn/M}, \quad m = 0, 1, \ldots, M - 1$$

为了符合图像坐标系统的直觉，将离散索引 $n \to x$，频域索引 $m \to u$，得到标准一维 DFT 对：

正变换 (Forward DFT)：

$$F(u) = \sum_{x=0}^{M-1} f(x)e^{-j2\pi ux/M}, \quad u = 0, 1, \ldots, M - 1$$

逆变换 (Inverse DFT / IDFT)：

$$f(x) = \frac{1}{M} \sum_{u=0}^{M-1} F(u)e^{j2\pi ux/M}, \quad x = 0, 1, \ldots, M - 1$$

当你对长度为 M 的有限离散序列 $f(x)$ 执行 DFT 时，DFT 的数学假设是 $f(x)$ 是一个无限延伸、以 M 为周期的周期信号。这种隐式周期性直接引出了环形卷积（Circular Convolution）。

根据周期性，卷积核越出左边界时，会立刻从右边界“卷回（Wraparound）”，如果不做零填充（Zero Padding），频域乘法算出来的不是常规的空间线性卷积，而是环形卷积，这会导致图像左右、上下边缘互相污染（Wraparound Error）。所以会建议进行频域滤波前，图像必须补零填充到至少 $P \geq A + C - 1$ 的尺寸。

与一维情况类似，二维冲激函数在积分运算下表现出筛选性质（Sifting Property）：

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(t,z)\delta(t,z)\,dt\,dz = f(0,0)$$

或者更通用地，对于位于坐标点 (t_0, z_0) 处的冲激函数：

$$\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(t,z)\delta(t-t_0,z-z_0)\,dt\,dz = f(t_0,z_0)$$

对于离散变量 x 和 y，二维离散单位冲激函数定义为：

$$\delta(x,y) = \begin{cases} 1, & \text{若} x = y = 0 \\ 0, & \text{其他} \end{cases}$$

其筛选性质为：

$$\sum_{x=-\infty}^{\infty}\sum_{y=-\infty}^{\infty} f(x,y)\delta(x,y) = f(0,0)$$

$f(x,y)$ 是离散变量 x 和 y 的函数。对于位于坐标 (x_0, y_0) 处的冲激，其筛选性质为：

$$\sum_{x=-\infty}^{\infty}\sum_{y=-\infty}^{\infty} f(x,y)\delta(x-x_0,y-y_0) = f(x_0,y_0)$$

令 $f(t,z)$ 为两个连续变量 t 和 z 的连续函数。二维连续傅里叶变换对由以下表达式给出：

$$F(\mu,\nu) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(t,z)e^{-j2\pi(\mu t+\nu z)}\,dt\,dz$$

以及（逆变换）：

$$f(t,z) = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} F(\mu,\nu)e^{j2\pi(\mu t+\nu z)}\,d\mu\,d\nu$$

与一维情况类似，变量 μ 和 ν 的定义域构成了连续频域。

一些性质：平移不变性（Translation Invariance），旋转等变性与对数极坐标变换（Log-Polar Fourier Transform）等，下面有 DFT 定义和关系表达的总结。

	Name	Expression(s)
1)	Discrete Fourier transform (DFT) of $f(x,y)$	$F(u,v) = \sum_{x=0}^{M-1}\sum_{y=0}^{N-1} f(x,y)e^{-j2\pi(ux/M+vy/N)}$
2)	Inverse discrete Fourier transform (IDFT) of $F(u,v)$	$f(x,y) = \frac{1}{MN}\sum_{u=0}^{M-1}\sum_{v=0}^{N-1} F(u,v)e^{j2\pi(ux/M+vy/N)}$
3)	Spectrum	$\lvert F(u,v)\rvert = \left[R^2(u,v) + I^2(u,v)\right]^{1/2}$ $R = \text{Real}(F)$; $I = \text{Imag}(F)$
4)	Phase angle	$\phi(u,v) = \tan^{-1}\left[\frac{I(u,v)}{R(u,v)}\right]$
5)	Polar representation	$F(u,v) = \lvert F(u,v)\rvert e^{j\phi(u,v)}$
6)	Power spectrum	$P(u,v) = \lvert F(u,v)\rvert^2$
7)	Average value	$\bar{f} = \frac{1}{MN}\sum_{x=0}^{M-1}\sum_{y=0}^{N-1} f(x,y) = \frac{1}{MN}F(0,0)$
8)	Periodicity (k_1 and k_2 are integers)	$F(u,v) = F(u+k_1M,v) = F(u,v+k_2N)$ $= F(u+k_1,v+k_2N)$ $f(x,y) = f(x+k_1M,y) = f(x,y+k_2N)$ $= f(x+k_1M,y+k_2N)$
9)	Convolution	$(f \star h)(x,y) = \sum_{m=0}^{M-1}\sum_{n=0}^{N-1} f(m,n)h(x-m,y-n)$
10)	Correlation	$(f \star h)(x,y) = \sum_{m=0}^{M-1}\sum_{n=0}^{N-1} f^*(m,n)h(x+m,y+n)$
11)	Separability	The 2-D DFT can be computed by computing 1-D DFT transforms along the rows (columns) of the image, followed by 1-D transforms along the columns (rows) of the result. See Section 4.11.
12)	Obtaining the IDFT using a DFT algorithm	$MNf^*(x,y) = \sum_{u=0}^{M-1}\sum_{v=0}^{N-1} F^*(u,v)e^{-j2\pi(ux/M+vy/N)}$ This equation indicates that inputting $F^*(u,v)$ into an algorithm that computes the forward transform (right side of above equation) yields $MNf^*(x,y)$. Taking the complex conjugate and dividing by MN gives the desired inverse. See Section 4.11.

Figure 4: Summary of DFT definitions and corresponding expressions.

	Name	DFT Pairs
1)	Symmetry properties	See Table 4.1
2)	Linearity	$af_1(x,y) + bf_2(x,y) \Leftrightarrow aF_1(u,v) + bF_2(u,v)$
3)	Translation (general)	$f(x,y)e^{j2\pi(u_0x/M + v_0y/N)} \Leftrightarrow F(u-u_0, v-v_0)$ $f(x-x_0, y-y_0) \Leftrightarrow F(u,v)e^{-j2\pi(ux_0/M + vy_0/N)}$
4)	Translation to center of the frequency rectangle, $(M/2, N/2)$	$f(x,y)(-1)^{x+y} \Leftrightarrow F(u-M/2, v-N/2)$ $f(x-M/2, y-N/2) \Leftrightarrow F(u,v)(-1)^{u+v}$
5)	Rotation	$f(r,\theta+\theta_0) \Leftrightarrow F(\omega,\varphi+\theta_0)$ $r = \sqrt{x^2+y^2} \quad \theta = \tan^{-1}(y/x) \quad \omega = \sqrt{u^2+v^2} \quad \varphi = \tan^{-1}(v/u)$
6)	Convolution theorem†	$f \star h)(x,y) \Leftrightarrow (F \bullet H)(u,v)$ $(f \bullet h)(x,y) \Leftrightarrow (1/MN)\left[(F \star H)(u,v)\right]$
7)	Correlation theorem†	$(f \star h)(x,y) \Leftrightarrow (F^* \bullet H)(u,v)$ $(f^* \bullet h)(x,y) \Leftrightarrow (1/MN)\left[(F \star H)(u,v)\right]$
8)	Discrete unit impulse	$\delta(x,y) \Leftrightarrow 1$ $1 \Leftrightarrow MN\delta(u,v)$
9)	Rectangle	$\text{rec}[a,b] \Leftrightarrow ab\frac{\sin(\pi ua)}{(\pi ua)}\frac{\sin(\pi vb)}{(\pi vb)}e^{-j\pi(ua+vb)}$
10)	Sinc	$\sin(2\pi u_0x/M + 2\pi v_0y/N) \Leftrightarrow \frac{jMN}{2}\left[\delta(u+u_0, v+v_0) - \delta(u-u_0, v-v_0)\right]$
11)	Cosine	$\cos(2\pi u_0x/M + 2\pi v_0y/N) \Leftrightarrow \frac{1}{2}\left[\delta(u+u_0, v+v_0) + \delta(u-u_0, v-v_0)\right]$

The following Fourier transform pairs are derivable only for continuous variables, denoted as before by t and z for spatial variables and by μ and ν for frequency variables. These results can be used for DFT work by sampling the continuous forms.

12)	Differentiation (the expressions on the right assume that $f(\pm\infty, \pm\infty) = 0$.)	$\left(\frac{\partial}{\partial t}\right)^m\left(\frac{\partial}{\partial z}\right)^n f(t,z) \Leftrightarrow (j2\pi\mu)^m(j2\pi\nu)^n F(\mu,\nu)$ $\frac{\partial^m f(t,z)}{\partial t^m} \Leftrightarrow (j2\pi\mu)^m F(\mu,\nu); \quad \frac{\partial^n f(t,z)}{\partial z^n} \Leftrightarrow (j2\pi\nu)^n F(\mu,\nu)$
13)	Gaussian	$A2\pi\sigma^2 e^{-2\pi^2\sigma^2(t^2+z^2)} \Leftrightarrow Ae^{-(\mu^2+\nu^2)/2\sigma^2}$ (A is a constant)

Figure 5: Summary

频域滤波

频域滤波的理论支柱是卷积定理（Convolution Theorem）：

$$f(x,y) * h(x,y) \iff F(u,v)H(u,v)$$

$$f(x,y)h(x,y) \iff F(u,v) * H(u,v)$$

空间域的离散卷积运算，等价于频域的逐点相乘（Pointwise Multiplication）。

离散傅里叶变换隐式假设信号具有周期性扩展。如果直接在频域对有限长度信号进行乘积滤波，会导致空间域的环形卷积（Circular Convolution），从而产生边缘缠绕失真（Wraparound Error）。为了获得与空间域线性卷积完全一致的结果，必须对输入图像 $f(x,y)$（大小 $A \times B$）和滤波器 $h(x,y)$（大小 $C \times D$）进行 zero-padding，补零至填充尺寸 $P \geq A + C - 1$ 和 $Q \geq B + D - 1$。

频域滤波器（Lowpass, Highpass, Bandpass, Notch）

频域滤波器 $H(u,v)$ 用于有选择地保留或抑制特定空间频率：

滤波器类型	理想传递函数特点	高斯传递函数特点	取证关键应用
低通 (LPF)	在截止频率 D_0 处陡峭截断，引起**振铃效应（Ringing / Gibbs Phenomenon）**	曲线平滑过渡 $H(u,v) = e^{-D^2(u,v)/2D_0^2}$，无振铃	检测平滑/模糊模糊干预、高频噪声压制
高通 (HPF)	$1 - H_{LPF}(u,v)$，截断边缘高频	提取高频细节与边缘	提取传感器噪声（PRNU）、高频高阶残差分析
带通/带阻 (BPF/BRF)	仅允许/阻止某一频段通过	针对特定频段抑制	分离特定尺度（如网格、加网印刷纹理）
陷波 (Notch Filter)	在特定点 (u_0, v_0) 及其对称点对称阻断	精细抹除孤立频点	消除周期性网格干扰、半色调网点、扫面行线

Figure 6: 频域滤波器的比较